

Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное
образовательное учреждение высшего образования
«Ульяновский государственный технический университет»
Кафедра «Информационные системы и технологии»

Методы и технологии интеллектуальной обработки и анализа данных
Лабораторная работа №3
«Исследование алгоритма регрессии»

Выполнила:
Кулагина П.С.
ИСТмд-11

Проверил:
Шишкин В.В.
к.т.н, доцент кафедры «ИВК»

г. Ульяновск

2025

1. Формулировка проблемы

Регрессионный анализ используется для прогнозирования непрерывных значений целевой переменной и оценки точности этих прогнозов через числовые ошибки. В отличие от классификации, здесь важно не только определить направление прогноза, но и величину отклонения результата от реального значения.

Данные включают числовые, категориальные и текстовые признаки, которые по-разному влияют на точность прогноза. Особенно интересным является влияние текстовой информации, потенциально добавляющей полезный сигнал, но также способной привнести шум. Поэтому важно исследовать, как регрессионные алгоритмы справляются с разнородными признаками и насколько меняется качество аппроксимации при усложнении данных.

2. Гипотеза

Предполагается, что ансамблевая регрессионная модель GradientBoostingRegressor, способная выявлять сложные нелинейные зависимости между признаками, обеспечит более высокую точность прогноза при использовании комбинированного набора признаков (табличных и текстовых), чем при применении только табличных или только текстовых данных. Ожидается, что добавление текстового признака повысит полноту информации о сотруднике и позволит модели уменьшить систематическую ошибку прогноза (MAE и RMSE), а также увеличить коэффициент детерминации R^2 .

3. План исследования

1. Определить целевую переменную Performance_Score и разделить признаки на числовые, категориальные и текстовые.
2. Сформировать три конфигурации признакового пространства: табличные признаки (числовые + категориальные), текстовый признак, группировка признаков.

3. Разделить выборку на обучающую и тестовую подвыборки в пропорции 80/20.
4. Построить единый конвейер обработки данных для каждой конфигурации признаков.
5. Обучить модель GradientBoostingRegressor в каждой конфигурации признакового пространства.
6. Выполнить прогноз на тестовой выборке и вычислить значения метрик R^2 , MAE и RMSE.
7. Построить графики: соответствия истинных и предсказанных значений, распределения остатков, зависимости остатков от предсказанных значений.
8. Сравнить результаты моделей между собой и сформулировать вывод о влиянии состава признаков на точность прогноза.

4. План эксперимента

Эксперимент нацелен на проверку гипотезы о том, что Gradient Boosting при использовании комбинированного признакового пространства (табличные + TF-IDF текста) обеспечивает лучшую аппроксимацию целевой переменной, чем при использовании только табличных или только текстовых признаков.

Данные приводятся к единому формату, отсутствующие значения обрабатываются в конвейере предобработки. Выборка делится на обучающую и тестовую части в пропорции 80/20 с фиксированным `random_state` (для воспроизводимости).

Рассматриваются три независимые конфигурации:

- Tabular: числовые признаки (масштабирование `StandardScaler`) + категориальные (`OneHotEncoder`),
- Text: только текстовый признак `TextFeature`, полученный конкатенацией доступных должностных/отдельных атрибутов и

преобразованный в векторы TF-IDF,

- Combined: объединение табличных и текстовых преобразований в едином ColumnTransformer.

Для каждой конфигурации обучается GradientBoostingRegressor в составе Pipeline(preprocessor → model). Основная метрика — R^2 (доля объяснённой дисперсии целевой переменной). Дополнительно вычисляются MAE (средняя абсолютная ошибка) и RMSE (квадратичная ошибка в корне) как показатели масштаба отклонений и чувствительности к выбросам.

Для лучшей конфигурации строятся: диаграмма y_true vs y_pred (оценка смещения и охвата диапазона), распределение остатков ($y_true - y_pred$) и график остатки+прогноз (проверка гетероскедастичности и систематических сдвигов), сравнительный анализ MAE и RMSE (чувствительность к крупным промахам). Так же рассчитывается Permutation Importance на тестовой части (или на удержанном подмножестве), чтобы установить, какие группы признаков (табличные и текстовые) дают наибольший вклад в уменьшение ошибки.

Гипотеза считается подтверждённой, если на тестовой части конфигурация Combined + Gradient Boosting демонстрирует наивысший R^2 при одновременно меньших MAE/RMSE, чем Tabular и Text по отдельности, а анализ остатков не выявляет выраженного систематического смещения. В противном случае формулируются условия, при которых комбинирование признаков не даёт преимуществ (например, доминирование шума в тексте или переобучение).

5. Реализация эксперимента

Работа с исходными данными показала, что структура выборки существенно влияет на построение регрессионной модели. Первичная загрузка и исследование набора данных выявили, что признак Employee_ID имеет уникальные значения для всех наблюдений и не несёт информативной

нагрузки — он был исключён заранее, чтобы избежать ложного увеличения размерности признакового пространства.

При распределении признаков по типам оказалось, что числовые и категориальные признаки представлены достаточно равномерно, в то время как текстовый признак содержит краткие описания сотрудников. Эти описания имеют небольшой объём и однотипную структуру, что впоследствии повлияло на результаты работы модели, использующей только текстовые данные.

Для предобработки данных был сформирован единый конвейер, в котором числовые признаки нормализовались, категориальные кодировались посредством One-Hot Encoding, а текстовый признак преобразовывался методом TF-IDF с ограничением размера словаря. Практически это позволило обеспечить сопоставимость всех вариантов моделирования и избежать утечки информации между выборками.

Обучение модели GradientBoostingRegressor проходило стабильно для наборов с табличными признаками: модель быстро сходилась, и значения ошибки на тренировочной и тестовой выборке были близкими, что свидетельствует об отсутствии переобучения. При обучении модели только на текстовых признаках наблюдалась противоположная ситуация: модель фактически не смогла уловить закономерности в данных и давала усреднённый прогноз вне зависимости от целевого значения. Это проявилось в значительном MAE и RMSE и почти нулевом коэффициенте детерминации R^2 . Сам процесс обучения при этом завершался корректно и быстро, но качество предсказаний было низким, что связано с ограниченной вариативностью и слабой связью текстового описания с целевой переменной.

При обучении комбинированной модели, объединяющей табличные и текстовые признаки, не было зафиксировано какого-либо прироста качества относительно варианта с одними табличными признаками. Значения R^2 , MAE

и RMSE остались на том же уровне. На графиках остатков также не появилось новых структурных закономерностей, указывающих на недоучёт факторов. Это говорит о том, что комбинированная модель не дала прироста качества.

Графики распределения остатков и зависимости истинных значений от прогнозируемых были сохранены и использовались для визуального анализа модели. Для табличной и комбинированной моделей остатки распределены равномерно вокруг нуля, что подтверждает корректность обучения. Для текстовой модели остатки имеют выраженную структурированность и значительную амплитуду, что отражает неспособность модели уловить зависимость.

Проанализируем полученные графики:

1. Модель на табличных признаках.




Рис 1. Анализ модели на табличных признаках

На рис. 1 видно, что распределение остатков имеет форму, близкую к симметричной (график слева). Большинство значений сгруппировано вблизи нулевой линии, что указывает на небольшие отклонения предсказаний и отсутствие систематической ошибки. На графике посередине точки расположены хаотично, без выраженной структуры. Это означает, что модель не допускает одинаковых систематических ошибок для разных диапазонов прогнозов, и следовательно, её поведение является устойчивым. На графике соответствия истинных и предсказанных значений (график справа) точки

плотно лежат вдоль диагонали, что подтверждает высокое качество регрессии.

2. Модель на текстовом признаке.




Рис 2. Анализ модели на текстовых признаках

На рис.2 график слева отличается широким размахом и выраженной неоднородностью. Остатки образуют несколько «полос», что особенно хорошо видно на среднем графике: точки группируются ярусами, отражая то, что модель фактически даёт одинаковый прогноз для разных объектов. На графике справа все точки сконцентрированы в узкой полосе вокруг одного предсказанного значения. Таким образом, модель практически не использует текст как информативный источник и сводит предсказания к усреднению, что объясняет низкие метрики качества.

3. Комбинированная модель (табличные + текстовые признаки).




Рис 3. Анализ комбинированной модели

Графики остатков и соответствия истинных и предсказанных значений, показанные на рис. 3, визуальнo совпадают с результатами табличной модели. Это подтверждает, что добавление текстового признака не только не

улучшило точность, но в реальности оказалось нейтральным. Модель фактически игнорирует текстовую компоненту, поскольку она не содержит дополнительных значимых зависимостей, не учтённых табличными признаками.

6. Вывод

Проведённое исследование подтвердило, что качество регрессионной модели в значительной степени определяется информативностью признаков, а не только выбором алгоритма. Модель Gradient Boosting показала высокую точность при использовании табличных признаков: коэффициент детерминации R^2 оказался близким к 1, а значения MAE и RMSE были низкими, что говорит о корректной аппроксимации целевой переменной и отсутствии выраженной систематической ошибки.

Использование только текстового признака не дало приемлемых результатов: модель практически сводила прогноз к среднему значению, что отразилось в низком R^2 и высокой ошибке. Это означает, что данный текстовый признак не содержит выраженных зависимостей, необходимых для восстановления значения Performance_Score.

Комбинированная модель (табличные + текстовые признаки) не улучшила качество прогноза по сравнению с табличной моделью. Значения R^2 , MAE и RMSE остались на том же уровне, а анализ остатков не выявил признаков повышения устойчивости или устранения смещения. Следовательно, добавление текстовой информации не увеличило информационную ёмкость признакового пространства.

Полученные результаты позволяют сделать вывод, что в рассматриваемом наборе данных ключевые зависимости между признаками и целевой переменной отражены в табличных данных, в то время как текстовая составляющая либо является избыточной, либо не связана с продуктивностью сотрудников. Таким образом, гипотеза о повышении качества модели при использовании комбинированного признакового пространства не подтвердилась.